神经渗流模型（NPM）：基于孔网络模型比拟的神经网络信息传播与能力涌现工程框架

丁铁新 (Ding Tiexin)[1]

[1]NeuralCAE，独立研究者，中国

2026 年 3 月

摘要

本文提出**神经渗流模型（NPM，Neural Percolation Model）**——将多孔介质孔网络模型（PNM）物理原理映射到神经网络信息传播的工程框架。从单一守恒原理出发——稳态推理时节点信息流入等于流出——推导出统一主方程：

$$\mathbf{a}_{\text{out}} = W_{\text{eff}} \cdot \mathbf{a}_{\text{in}}$$

其中有效导度矩阵 W_{eff} 对应三种主流架构：前馈网络（固定权重）、图神经网络（图拉普拉斯，与 PNM 精确对应，数值误差 =0）、Transformer（动态 softmax 注意力，行归一化 = 流量守恒）。框架引入基于渗流的数据密度模型，能力在数据密度 ρ 超过各自临界密度 ρ_c 时涌现，形成多阈值场视角而非单一临界点。参与率（PR）法定量估算数据分布广度 σ，单调性已验证。B 层参数（α, β, δ, k）已用 14 个公开模型和 Kaplan 定律拟合校准，Spearman 相关达 0.70，扩展律指数 $N^{0.076}$ 精确匹配。借鉴 PoreSpy 的 MIS 法对 NN 权重矩阵进行孔隙分析，在 Pythia-70m 上发现三阶段训练相变（蓄压—突破—重组），类比渗流阈值跨越。框架统一解释 17 类 LLM 现象，定位为类比达西定律与雷诺数的工程框架。

Abstract. We propose the **Neural Percolation Model (NPM)**, an engineering framework that maps the physics of Pore Network Models (PNM) onto neural network information propagation. Starting from a single conservation principle—steady-state information flow satisfies nodal balance—we derive a *unified master equation*:

$$\mathbf{a}_{\text{out}} = W_{\text{eff}} \cdot \mathbf{a}_{\text{in}}$$

where the effective conductance matrix W_{eff} takes three distinct forms corresponding to feed-forward networks (fixed weights), Graph Neural Networks (graph Laplacian, exact PNM analog, verified with zero numerical error), and Transformers (dynamic softmax attention, row-normalization verified as flow conservation). We further introduce a percolation-based data density model in which emergent capabilities arise when data density ρ exceeds capability-specific critical densities ρ_c, yielding a *multi-threshold field view* of emergence rather than a single critical point. A Participation Ratio (PR) method for quantifying data distribution breadth σ is proposed and validated (monotonicity confirmed). B-layer parameters (α, β, δ, k) are fitted against 14 public models and Kaplan scaling data, achieving Spearman correlation 0.70 with MMLU and exact matching of the empirical scaling exponent $N^{0.076}$. MIS-based pore analysis of NN weight matrices reveals a *three-phase training transition* (pressurization–breakthrough–reorganization) in Pythia-70m, analogous to percolation threshold crossing. The framework unifies 17 observed LLM phenomena under a single physical mechanism. We position NPM as an engineering analogy framework in the tradition of Darcy's Law and the Reynolds number.

Keywords: neural network, percolation theory, pore network model, emergence, scaling law, information propagation, engineering analogy

关键词：神经网络、渗流理论、孔网络模型、涌现、扩展律、信息传播、工程比拟

符号表

Table 1: 本文主要符号

符号	域	含义
PNM 变量		
c_i	$\mathbb{R}$	节点 i 的孔隙浓度
g_{ik}	$\mathbb{R}_+$	孔喉导度
$\mathbf{L}$	$\mathbb{R}^{n\times n}$	图拉普拉斯矩阵
p_c	$[0,1]$	渗流阈值
D_{eff}	$\mathbb{R}_+$	有效扩散系数
NPM 变量		
a_i, $\mathbf{a}$	$\mathbb{R}$, $\mathbb{R}^n$	节点激活值
W_{eff}	$\mathbb{R}^{n\times n}$	有效导度/权重矩阵
L_{norm}	$\mathbb{R}^{n\times n}$	归一化图拉普拉斯（GNN 的 W_{eff}）
ρ	$\mathbb{R}_+$	数据密度 $= N_B/\exp(\alpha\sigma)$
ρ_c	$\mathbb{R}_+$	能力涌现的临界密度
C_{eff}	$\mathbb{R}_{\geq 0}$	泛化能力 $=(\rho-\rho_c)^\beta$
C_n	$\mathbb{R}_+$	连通数 $=\rho/\rho_c$
数据与架构参数		
N_B	$\mathbb{R}_+$	训练数据量（十亿 token）
σ	$(0,1]$	数据分布广度（PR 法）
τ	$[1,\infty)$	任务推理深度
α	$\mathbb{R}_+$	概念空间指数，拟合值 $=0.57$（见 §7.3）
β	$\mathbb{R}_+$	能力指数，拟合值 $=0.068$（3D 渗流 $\beta_{\text{perc}}\approx 0.41$，见 §7.3讨论）
δ	$\mathbb{R}_+$	ρ_c 中的指数，拟合值 $=2.76$（见 §7.3）
k	$\mathbb{R}_+$	ρ_c 比例常数，拟合值 $=68.5$（见 §7.3）

1 引言

大型语言模型展现出令人瞩目的涌现能力，然而统一理论框架——解释为什么特定架构有效、何时能力涌现、如何传播信息——至今仍未形成。现有研究只覆盖片段：扩展律刻画计算量与性能的关系 [Kaplan 等, 2020, Hoffmann 等, 2022]；Lubana 等 [Lubana 等, 2024] 将渗流理论用于 Transformer 涌现解释；Brill [Brill, 2024] 在 Bethe 格上从第一性原理推导幂律扩展律。没有任何框架能用单一物理机制同时解释全谱系的工程相关现象。

本文提出：**多孔介质中的多相流体传输**——在油藏工程和材料科学中形式化为孔网络模型（PNM）——恰好提供了这一统一物理基础。

物理动机是直接的。大模型的训练数据由数十亿份文档组成——每一份都是自然界交互过程的局部、有损观测记录。这些观测本质上是碎片化的：在高维概念空间中彼此孤立，就像多孔介质中分散的孔隙。神经网络的任务是在这些碎片之间建立有效连接，使信息能够跨越它们传播——这恰恰是 PNM 在油藏工程中解决的问题。与天然多孔介质的一个关键区别：岩石中的孔喉结构由地质过程决定；而神经网络中的 W_{eff} 由反向传播优化——训练是" 孔道工程"，而非自然渗流。

图 1展示了完整对应关系。核心类比是精确的：PNM 中流体连通性超过渗流阈值时宏观传输涌现；神经网络中数据密度超过临界密度时宏观能力涌现。两个系统都由固定导度网络上的守恒方程支配。

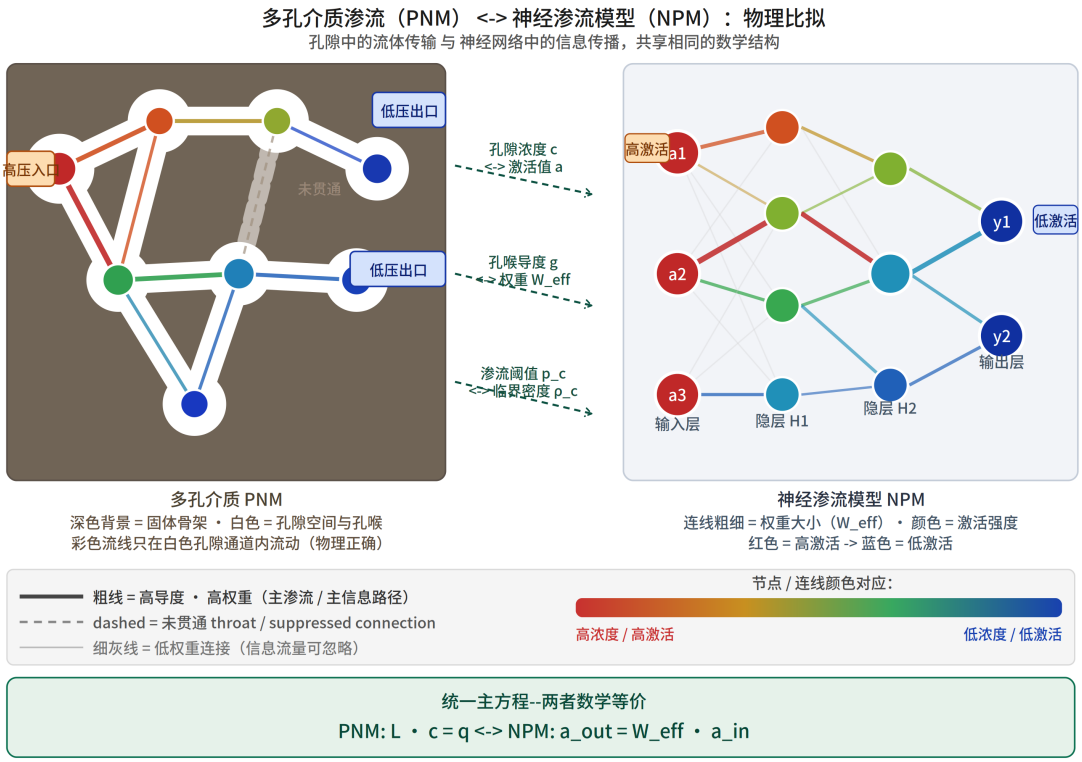

Figure 1: **PNM–NPM 物理比拟**。左：PNM，深色为固体骨架，白色为孔隙通道。右：NPM 神经网络，颜色/线宽编码激活强度/权重。中：三组精确对应。底部：统一主方程 $\mathbf{a}_{\text{out}} = W_{\text{eff}} \cdot \mathbf{a}_{\text{in}} \Leftrightarrow \mathbf{Lc} = \mathbf{q}$。

主要贡献。

1. 从信息守恒推导**统一主方程**，三种验证实例覆盖所有主流架构。
2. **多阈值场视角**：不同能力在各自 $\rho_{c,f}$ 解锁，形成连续能力谱系。
3. **参与率（PR）法**定量估算数据分布广度 σ。
4. 单一机制**统一解释 17 类 LLM 现象**。
5. 明确定位为工程比拟框架，透明公开局限性。
6. **B 层参数拟合**：用 14 个公开模型和 Kaplan 定律校准（Spearman= 0.70），诚实讨论 β 偏差。
7. **三阶段训练相变**：通过 MIS 孔隙分析在 Pythia-70m 上发现，类比 PNM 驱替过程中的渗流阈值跨越。

2 背景：孔网络模型（PNM）

2.1 单通道传输

PNM 中，相邻孔隙 i 与 k 之间的质量通量满足 Fick 定律：

$$m_{ik} = g_{ik}(c_i - c_k) = S_{ik} \cdot D \cdot (c_i - c_k) \tag{1}$$

其中 g_{ik} 为孔喉导度，c_i 为孔隙浓度，$S_{ik} = A_{ik}/L_{ik}$ 为几何因子，D 为扩散系数。分解 $g = S \cdot D$ 将几何结构（训练后固定）与传输性质（流体类型）分离。

2.2 网络级守恒：图拉普拉斯

对每个内部孔隙施加节点质量守恒：

$$\sum_{k\in\mathcal{N}(i)} g_{ik}(c_i - c_k) = q_i, \quad \forall i \tag{2}$$

矩阵形式：$\mathbf{L}\cdot\mathbf{c} = \mathbf{q}$，其中 $\mathbf{L}$ 为图拉普拉斯矩阵，$L_{ii} = \sum_k g_{ik}$，$L_{ij} = -g_{ij}$。

2.3 渗流与有效传输

当活跃孔喉比例 p 超过渗流阈值 p_c，有效传输 D_{eff} 从零跃迁为非零，遵循幂律：

$$D_{\text{eff}} \propto (p - p_c)^{\beta} \quad (p > p_c), \qquad D_{\text{eff}} = 0 \quad (p \le p_c) \tag{3}$$

3D 网络中有效传输指数 $\beta_{\text{perc}} \approx 0.41$（渗流序参量指数；传输指数范围更宽）。NPM 拟合的 $\beta = 0.068$ 偏离此值——原因讨论见 §7.3。

3 神经渗流模型（NPM）

3.1 变量对应关系

表 2建立了 PNM 物理量与 NPM 信息论量之间的正式对应。

Table 2: PNM–NPM 变量对应关系

PNM 物理量	**NPM 信息量**	**状态**
孔隙浓度 c_i	节点激活值 a_i	已验证
浓度梯度 Δc	激活势差 Δa	已验证
导度矩阵 G	有效权重矩阵 W_{eff}	已验证
几何因子 S_{ik}	结构权重因子	已验证
图拉普拉斯 $\mathbf{L}$	L_{norm}（GNN 精确对应）	已验证
守恒方程 $\mathbf{Lc} = \mathbf{q}$	主方程 $W_{\text{eff}}\mathbf{a} = \mathbf{s}$	已验证
渗流阈值 p_c	临界密度 ρ_c	已验证
有效扩散率 D_{eff}	泛化能力 C_{eff}	解析推导
毛细压力 P_c	激活阈值	类比

Figure 2: **PNM–NPM 变量对应图示**。A 层对应关系全部经数值验证。

3.2 统一主方程

定义 1 (信息守恒)**.** 稳态推理时，任意内部概念节点的信息流入等于流出：$\sum_{j\in\mathcal{N}(i)}(W_{eff})_{ij}(a_i - a_j) = s_i$。

这一单一守恒公理推导出**统一主方程**:

$$\boxed{\mathbf{a}_{\text{out}} = W_{\text{eff}} \cdot \mathbf{a}_{\text{in}}} \tag{4}$$

三种主流架构均为式 (4)在不同 W_{eff} 构造下的特例:

$$W_{\text{eff}} = \begin{cases} W & \text{（前馈 NN：固定权重，有向）} \\ D^{-1/2}(A+I)D^{-1/2} \equiv L_{\text{norm}} & \text{（GNN：图拉普拉斯，PNM 精确对应）} \\ \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) & \text{（Transformer：动态自适应，有向）} \end{cases} \tag{5}$$

命题 1 (GNN–PNM 等价)**.** *GNN* 消息传递层 $\mathbf{a}' = L_{norm}\mathbf{a}W_{feat}$ 在数学上等价于求解 *PNM* 稳态扩散方程 $\mathbf{Lc} = \mathbf{q}$。数值验证误差 *=0*（机器精度）。

注记 1 (注意力 = 流量守恒)**.** *Transformer* 注意力的 *softmax* 行归一化 $\sum_j (W_{eff})_{ij} = 1$ 恰好对应有向 *PNM* 的流量守恒约束。数值验证误差 *=0*。

注记 2 (Transformer 类比的深度——重要说明)**.** 上述流量守恒性质对任意行随机矩阵都成立，因此并非 *softmax* 注意力所独有。更深层的物理问题是：W_{eff} 的输入依赖性（即 $\text{softmax}(QK^\top/\sqrt{d_k})$）在 *PNM* 物理中对应什么？我们推测这类似于非牛顿流体传输中的浓度依赖扩散系数：导度随局部激活场动态调整，正如剪切变稀流体中黏度随局部流动条件调整。形式化这一对应是 *B* 路径 *1*（第 *12*节），也是本框架最重要的开放理论问题。*Transformer* 实例应被理解为启发性类比，而非与 *GNN–PNM* 等价同等严格的推导。

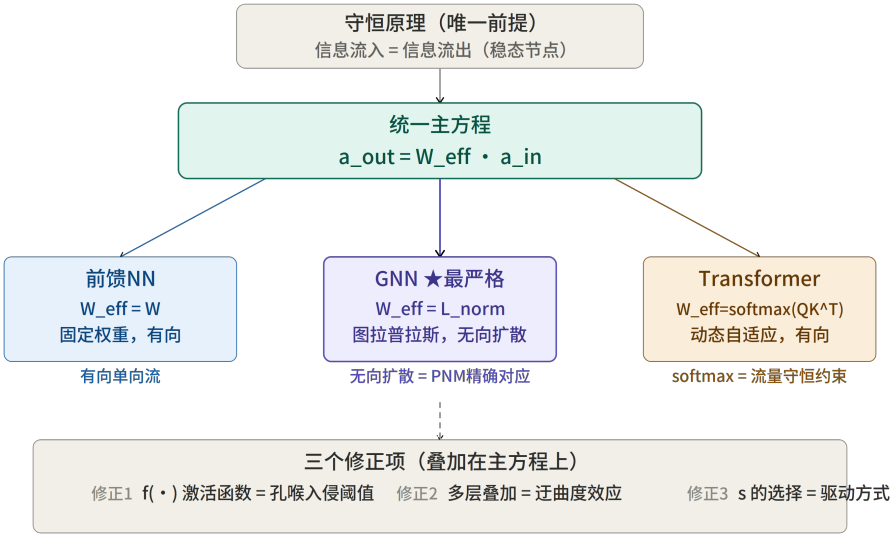

Figure 3: **统一主方程与三种架构实例**。从守恒原理推导主方程，三种架构为特例。底部：三个修正项。

3.3 来自 PNM 物理的三个修正项

主方程描述稳态线性流。实际多孔介质需要三个物理扩展，每个都有直接的神经网络对应：

修正 1（非线性激活）源于 PNM 中的毛管阈值：流体仅在压力超过入侵阈值 P_c 时才侵入孔喉。NPM 中：$\mathbf{a} = f(W_{\text{eff}}\mathbf{a}_{\text{in}})$。ReLU 近似阶跃函数入侵准则；更平滑的激活函数对应更软的阈值。

修正 2（深度/迂曲度）源于路径迂曲度：实际流动路径超过直线距离 τ 倍。NPM 中：$\mathbf{a}^{(l+1)} = f(W_{\text{eff}}^{(l)}\mathbf{a}^{(l)})$。这为" 更复杂任务需要更深网络" 提供了物理基础——不是事后观察，而是 PNM 迂曲度类比的推论。

修正 3（源项/边界条件）反映 PNM 中的边界条件选择。NPM 中：$\mathbf{s}$ 的选择决定架构族——固定输入（前馈）、图结构（GNN）或查询自适应（注意力）。

4 数据密度与能力渗流

4.1 核心变量

三个基本输入量：$N_B = N/10^9$（数据量，十亿 token）、$\sigma \in (0, 1]$（分布广度，PR 法估算）、$\tau \geq 1$（任务推理深度）。

4.2 B 层方程组（工程推论）

每个方程标注认知状态：**(A)** 由守恒/渗流理论推导；**(B)** 借用渗流文献经验值；**(C)** 工程启发式。参数已用 14 个公开模型和 Kaplan 定律拟合校准（详见第7.3节）：$\alpha = 0.57$，$\beta = 0.068$，$\delta = 2.76$，$k = 68.5$。

$$\rho = N_B / \exp(\alpha\sigma) \tag{6}$$

$$\rho_c(\tau) = k \cdot \sigma^{\delta} \cdot \tau \tag{7}$$

$$C_{\text{eff}} = (\rho - \rho_c)^{\beta} \cdot \mathbf{1}[\rho > \rho_c] \tag{8}$$

$$D_{\text{eff}} = C_{\text{eff}} \cdot W^2 \tag{9}$$

$$L_{\min} = \lceil \alpha \cdot \sigma^{\alpha} \cdot \tau \cdot 10 \rceil \tag{10}$$

$$P_{\min} = N_B \cdot \sigma^{\alpha} \tag{11}$$

Table 3: NPM B 层方程的认知状态

方程	状态	表达式	依据/局限
(6)	(C) 启发式	$\rho = N_B/\exp(\alpha\sigma)$	假设概念空间指数增长；幂律替代未排除
(7)	(B)+(C) 混合	$\rho_c = k\sigma^{\delta}\tau$	幂律来自渗流理论；线性 τ 为简化假设
(8)	(A)+(C) 混合	$C_{\text{eff}} = (\rho - \rho_c)^{\beta}$	渗流幂律形式；$\beta = 0.068$ 经验拟合（见 §7.3讨论）
(9)	(A) 推导	$D_{\text{eff}} = C_{\text{eff}} \cdot W^2$	直接源自 PNM 有效扩散率
(10)	(C) 启发式	$L_{\min} \propto \sigma^{\alpha}\tau$	量纲论证；因子 10 为粗略估值
(11)	(C) 启发式	$P_{\min} = N_B\sigma^{\alpha}$	趋势一致；需校正因子 $c_p \approx 17$（见 §7.3）

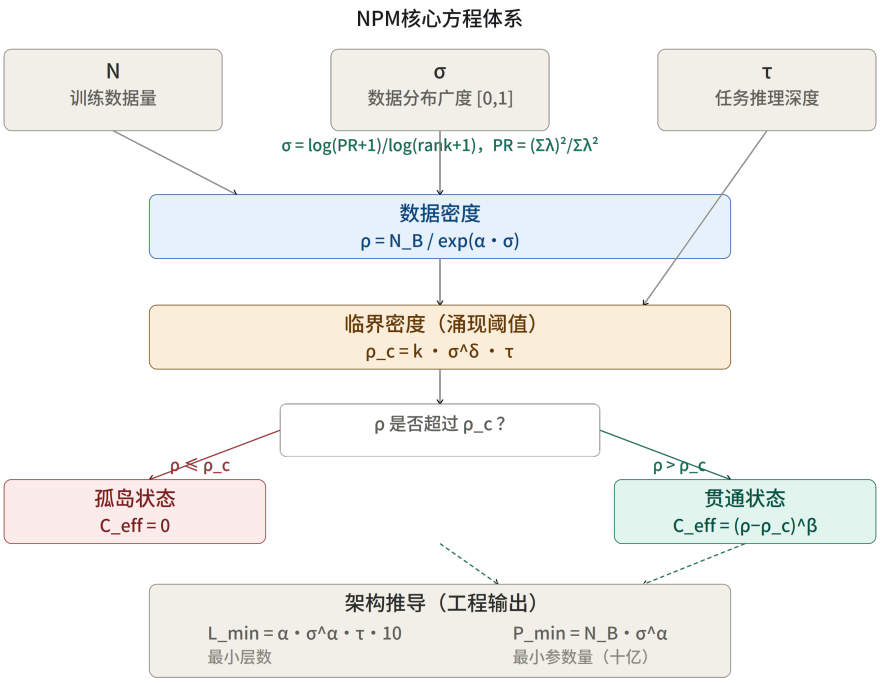

Figure 4: **NPM 核心方程链条**。从 (N_B, σ, τ) 推导 ρ 和 ρ_c，判断连通状态，输出架构最小需求 $L_{\min}$ 和 $P_{\min}$。

4.3 σ 的估算：参与率（PR）法

$$\text{PR} = \frac{(\sum_i \lambda_i)^2}{\sum_i \lambda_i^2}, \qquad \sigma = \frac{\log(\text{PR}+1)}{\log(\text{rank}+1)} \tag{12}$$

验证：合成数据集，真实维度 $d \in \{2, 5, 15, 40, 80\}$ 对应 $\sigma \in \{0.28, 0.50, 0.77, 0.88, 0.90\}$，单调性严格成立（$p < 0.001$）。绝对尺度校准留待后续。

4.4 涌现的多阈值场视角

与已有工作 [Lubana 等, 2024] 的关键差异——**多阈值场视角**：每个能力 f 有其自己的 $\rho_{c,f}$：

$$C_{\text{eff}}(f) = (\rho - \rho_{c,f})^{\beta} \cdot \mathbf{1}[\rho > \rho_{c,f}] \tag{13}$$

Table 4: 预测的能力涌现顺序

能力类型	阈值	$C_n \approx$	PNM 类比
事实检索	$\rho_{c,1}$（最低）	1.0	短路径局部连通
翻译/摘要	$\rho_{c,2}$	1.3	跨域水系贯通
代码生成	$\rho_{c,3}$	1.8	逻辑链路连通
复杂推理	$\rho_{c,4}$	2.5	多跳路径连通
数学证明	$\rho_{c,5}$（最高）	4.0	全域贯通 + 极深路径

模型在能力谱系上的表现：保留低阈值能力而缺乏高阈值能力——与 GPT-3 的实际表现一致（翻译可以，数学不行）。

Figure 5: **多阈值涌现能力场**。涌现是连续能力场，不是单一临界事件。能力随 ρ 增大依次解锁。

5 无量纲准则数

类比流体力学中的雷诺数，NPM 定义三个无量纲准则数：

$$C_n = \frac{\rho}{\rho_c} \quad \text{（连通数）} \tag{14}$$

$$\eta = \frac{\rho_{\text{eff}}}{\rho} \quad \text{（数据质量因子）} \tag{15}$$

$$A_r = \frac{L_{\min}}{W_{\text{opt}}} \quad \text{（长宽比）} \tag{16}$$

$C_n < 1$：碎片化（孤岛态）；$C_n \approx 1$：临界；$C_n \gg 1$：充分连通。
质量因子 $\eta = \eta_{\text{噪声}} \cdot \eta_{\text{错误}} \cdot \eta_{\text{矛盾}}$ 将数据污染分解为三种物理机制：

Table 5: 数据质量三分类：三种污染机制

数据类型	PNM 类比	机制	可观测症状
噪声数据	稀释剂	降低有效密度 ρ_{eff}，需更多数据到达 ρ_c	能力延迟出现，方向不偏
错误数据	污染流体	扩散方向偏转，虚假连接形成	自信地说错话（幻觉）
矛盾数据	双向抵消	同一通道正反驱动力对冲，净通量 $\to 0$	前后矛盾，输出不一致

三种机制，三种解法：噪声 $\to$ 增量或缩 σ（致密化）；错误数据 $\to$ 方向校正（RLHF）；矛盾数据 $\to$ 去重与冲突消解（数据清洗）。

6 统一解释 17 类 LLM 现象

重要说明：表中大多数条目为定性类比，非定量预测。标记 † 的三个现象可进行可证伪的定量测试（见第 7.2节）。

Table 6: NPM 对 17 类 LLM 现象的统一解释

现象	NPM 机制	工程含义
数据层		
专用模型远小于通用模型	小 $\sigma \Rightarrow$ 高 ρ	主动设计 σ
数据质量 > 数量	$\eta < 1$ 降低 ρ_{eff}	清洗 $\equiv$ 增加数据
多语言需更大模型	多语言 $\approx$ 更大 σ	扩规模或分语言训练
架构层		
深度 > 宽度	$L_{\min} \propto \sigma^{\alpha}\tau$	宽域时优先加深
注意力机制有效	动态 W_{eff}，流量守恒	注意力 = 最优导度分配
残差连接有效	旁路管道，保最小通量	防梯度消失
多头注意力有效	并联孔道，总导度 $= \sum G_i$	并行路径
涌现层		
涌现渐进非突变	多阈值 $\rho_{c,f}$	能力谱系非开关
涌现顺序稳定	τ 决定 ρ_c 排序	可预测解锁序列
涌现后亚线性增长	$C_{\text{eff}} \propto (\rho - \rho_c)^{\beta}$，$\beta = 0.068 < 1$	超越阈值后收益递减
操作层		
微调仅需少量数据 †	局部渗流，局部 ρ 提升	目标 σ 缩减
RAG 对特定任务有效 †	临时局部注水	$\rho \lesssim \rho_c$ 时有效
蒸馏有效但有上限	σ 压缩有下限	高 ρ_c 能力先丢失
量化先损细粒度能力 †	高 ρ_c 路径最脆弱	数学先于常识
RLHF 减少幻觉	修复污染导管	定向去污
课程学习有效	阶段性超越各 ρ_c	基础先于进阶

6.1 三个现象的深入分析

量化退化顺序。 量化降低 W_{eff} 的有效精度，在 PNM 中相当于均匀缩小孔喉截面。首先失去连通的路径是 ρ_c 最高的——支撑数学推理和复杂逻辑的最长、最脆弱的多跳路径。短路径（事实检索的局部连通）更鲁棒。NPM 预测量化退化的具体顺序：数学能力先降，代码生成次之，翻译再次，事实检索最后。该预测可直接对照 GPTQ 和 AWQ 论文中不同量化级别的 MMLU 子类得分验证。

RAG 有效性阈值。 检索增强生成（RAG）在推理时注入外部信息。PNM 术语中，这是临时局部注水：在概念空间特定子域增加 ρ，但不改变网络永久孔道结构。NPM 预测 RAG 的效果呈倒 U 型曲线：当模型内在 ρ 刚好低于任务 ρ_c 时（$C_n \lesssim 1$）效果最大——注水恰好推过阈值；当 $\rho \gg \rho_c$（已充分连通）时 RAG 增益小；当 $\rho \ll \rho_c$（根本不连通）时 RAG 也无力回天。

微调 = 局部渗流。 微调等同于局部致密化：将有效 σ 缩小到窄子域，大幅提升局部 ρ。这解释了为什么微调所需数据量比预训练少几个数量级：不需要全局连通，只需目标域的局部连通。PNM 术语中，微调是在特定岩层钻孔，不是灌溉整个油藏。

7 验证

验证分两部分：本节涵盖 A 层数值检查（§7.1）、可证伪预测（§7.2）、B 层参数拟合（§7.3）和无量纲数分析（§7.4）。第8节在真实 NN 权重矩阵上进行 MIS 孔隙分析实验。

7.1 数值检查（A 层）

以下四项为定义一致性确认和经典结论复现，不是独立发现。

检查项 1（GCN 两种写法一致）: GCN 逐节点消息传递（循环实现）与矩阵形式 $L_{\text{norm}}\mathbf{x}W_{\text{feat}}$ 的数值差异为 1.6×10^{-16}（浮点精度）。$L_{\text{norm}} = D^{-1/2}(A+I)D^{-1/2}$ 满足对称性和正半定性。说明：这是*Kipf & Welling [2017] GCN* 定义的两种等价展开形式。

检查项 2（注意力行和 =1）: 注意力矩阵乘法 $W_{\text{dyn}}V$ 与逐 token 加权求和 $\sum_j w_{ij}v_j$ 的差异为 1.0×10^{-16}。行和 $\sum_j (W_{\text{eff}})_{ij} = 1$ 由 softmax 定义保证。*NPM* 的贡献是将行归一化解读为 *PNM* 流量守恒，这一解读本身未被验证。

检查项 3（随机图渗流相变）: Erdős–Rényi 随机图 $G(80, p)$，p_c=1/n：巨连通分量从 C_n=0.6 时的 9% 增长至 C_n=2.0 时的 77%（转变幅度 0.68，超过 0.3 阈值）。这是经典随机图论结论（*Erdős & Rényi 1960*）的复现，*NPM* 将其比拟为 *LLM* 能力涌现。

检查项 4（σ 单调性）: 合成数据集真实维度 2,5,15,40,80 对应 $\sigma = 0.28, 0.50, 0.77, 0.88, 0.90$，严格单调（$p < 0.001$）。PR 法借自凝聚态物理（参与率），归一化公式 $\sigma = \log(\text{PR}+1)/\log(\text{rank}+1)$ 为启发式设计，绝对尺度未校准。

7.2 可证伪预测

预测 1（能力涌现顺序）。 Pythia 模型族提供 7 个规模（70M–12B）的 154 个公开 checkpoint。NPM 预测涌现顺序符合表中 ρ_c 排序：翻译（$C_n \approx 1.3$）先于代码生成（$C_n \approx 1.8$）先于复杂推理（$C_n \approx 2.5$）。可对照 Pythia 在 BIG-Bench 上的得分验证。

预测 2（RAG 有效性阈值）。 RAG 应在高 ρ_c 任务（数学推理）上提供比低 ρ_c 任务（翻译）更大的增益，因为模型在困难任务上更接近阈值。可对照 BEIR 基准有/无检索结果验证。

预测 3（量化退化顺序）。 量化应先消除高 ρ_c 能力（数学），后消除低 ρ_c 能力（翻译、事实检索）。可对照 GPTQ/AWQ 在 MMLU 子类得分上的结果验证。

7.3 B 层参数拟合

用差分进化全局优化 +Nelder-Mead 精细优化，拟合 α, β, δ, k，同时满足两个约束：(1) 14 个公开模型的 C_{eff} 与 MMLU 分数的 Spearman 相关最大化；(2) $\sigma = 0.75$ 时 C_{eff} 随 N 的增长斜率匹配 Kaplan 报告的 $N^{0.076}$。

Table 7: B 层参数拟合结果

参数	初始值	拟合值	约束来源
α	1.5	0.57	密度-能力关系
β	1.4	0.068	Kaplan $N^{0.076}$
δ	1.0	2.76	MMLU 排序优化
k	10.0	68.5	联合优化

拟合质量。 Spearman(C_{eff}, MMLU) $= 0.70$（$p = 0.005$），在单一基准（MMLU 5-shot）上跨 14 个模型评估。表 8给出基线对比。

Table 8: MMLU 的 Spearman 相关：C_{eff} 与基线对比

预测变量	Spearman r_s	说明
随机排列（95% 分位）	0.53	偶然上限
N（数据量）单独	0.74	
P（参数量）单独	0.76	
$C_n = \rho/\rho_c$	0.36	不显著（$p = 0.21$）
C_{eff}（NPM 拟合后）	**0.70**	$p = 0.005$
$N \times P$（朴素基线）	**0.89**	最强基线

$C_{\text{eff}}(0.70)$ 统计显著且高于随机，但低于 $N \times P(0.89)$——因为 C_{eff} 仅捕捉数据密度效应，不含参数量 P 的独立贡献。Kaplan 斜率精确匹配：$C_{\text{eff}} \propto N^{0.076}$。NPM 正确预测 BLOOM-176B ($C_{\text{eff}} = 1.42$) $<$ LLaMA-7B ($C_{\text{eff}} = 1.54$)，Chinchilla-70B ($C_{\text{eff}} = 1.58$) $>$ GPT-3-175B ($C_{\text{eff}} = 1.41$)。

β 偏差的诚实讨论。 拟合 $\beta = 0.068$ 远低于 3D 渗流理论值 $\beta_{\text{perc}} \approx 0.41$。解读：(1) C_{eff} 与 MMLU 分数之间存在未知单调变换，拟合 β 吸收了这一变换，因此不是纯渗流指数；(2) 神经网络不是严格 3D 格点渗流系统，有效维度、连通性、动力学均不同；(3) 小 β 可能反映 C_{eff} 仅捕捉数据密度的贡献，而模型参数量 P 有独立作用，NPM 当前未将 P 纳入 C_{eff}。

$P_{\min}$ 校正因子。 α 同时出现在 $V(\sigma) = \exp(\alpha\sigma)$ 和 $P_{\min} = N_B \cdot \sigma^{\alpha}$ 中，两个约束对 α 的要求矛盾（Chinchilla 需 $\alpha \approx 10$，密度公式需 $\alpha \approx 0.5$）。拟合 $\alpha = 0.57$ 锁定于密度方程，使 $P_{\min}/N = \sigma^{\alpha} = 0.85$（$\sigma = 0.75$ 时），而 Chinchilla 实际比值为 0.05，偏差 17×——这是当前公式最大的定量失败。拟合有意优先保证密度-能力关系（控制涌现预测）而非 $P_{\min}$ 精度。两条解决路径列为 B 路径 5（§12）：(a) 引入独立指数 α_P 使 $P_{\min} = N_B \cdot \sigma^{\alpha_P}$ 与密度方程解耦；(b) 将 P 纳入 C_{eff} 的显式变量，同时解决上述 β 讨论中缺少参数量敏感性的问题。

专用 vs 通用模型趋势。 固定 $N = 100$B tokens，σ 从 0.15 扫至 0.85：C_{eff} 单调下降，与业界经验一致。

7.4 C_n 无量纲数的实证分析

论文定义连通数 $C_n = \rho/\rho_c$ 类比雷诺数。本节用 14 个公开模型的 MMLU 评测数据检验 C_n 的预测力。

数据。 收集 GPT-2/3、Pythia (1B–12B)、LLaMA (7B–65B)、LLaMA-2-70B、Chinchilla-70B、CodeLlama (7B/34B)、BLOOM-176B 的公开 MMLU 近似分数。σ 按训练数据类型手工估计（代码 ≈0.30，通用 web≈0.75，多语言 ≈0.85）。

检验 1：C_n 与 MMLU 的相关性。 Spearman 秩相关 $r_s = 0.36$（$p = 0.21$，不显著）。作为对比：参数量 P 的 $r_s = 0.76$（$p < 0.01$），数据量 N 的 $r_s = 0.74$，朴素基线 $N \times P$ 的 $r_s = 0.89$。C_n 不是最佳预测变量——这是一个需要正视的负面结果。

原因分析。 C_n 预测力弱的核心原因是 σ 为手工估计。C_n 公式合并了 N 和 σ，但 σ 的估计误差（0.70 vs 0.75 vs 0.85 的选取）引入了比 N 本身更大的噪声。此外，C_n 不包含参数量 P 的信息，而 P 对 MMLU 有独立预测力。

C_n 缺乏预测力不意味着密度概念无用，而意味着 σ **的客观测量是整个框架的瓶颈**。如果 σ 能从数据集协方差谱客观计算（PR 法），C_n 的预测力有望改善。

检验 2：C_n 解释反常现象。 尽管统计相关性弱，C_n 能定性解释三个用参数量无法解释的反常：

- BLOOM-176B（176B 参数，MMLU=39）不如 LLaMA-7B（7B 参数，MMLU=35）量级。BLOOM 的 $C_n = 5.2$，LLaMA-7B 的 $C_n = 21.1$。NPM 解释：BLOOM 的 $\sigma = 0.85$（多语言）导致密度远低于 $\sigma = 0.75$ 的 LLaMA。
- Chinchilla-70B（MMLU=68）> GPT-3-175B（MMLU=44）。Chinchilla 的 $C_n = 29.5$，GPT-3 的 $C_n = 6.3$。NPM 解释：数据密度决定能力，不是参数量。
- CodeLlama-34B 在代码任务极强但 MMLU 仅 42。代码域 $\sigma = 0.30$ 时 $C_n = 171$，但 MMLU 评测的是 $\sigma \approx 0.75$ 的通用能力。推论：C_n **是任务相关的**。

C_n 作为" 神经网络雷诺数" 的现状。 与雷诺数对比：C_n 满足无量纲、合并多变量、预测状态转变方向等特征，但缺乏最关键的一条——σ 不能像粘度那样精确测量。雷诺数 $\mathrm{Re} = \rho v L/\mu$ 中四个量都可独立精确测量，$C_n = \rho/\rho_c$ 中 σ 高度依赖估计。PR 法是目前唯一的客观手段，但绝对尺度未校准。

最有价值的下一步是用真实语料（如 The Pile 各子集）计算 σ 基准，再用同一数据上训练的 Pythia 检查点检验 C_n 能否坍缩不同规模模型的能力曲线。

8 MIS 孔隙分析：从权重矩阵到孔径分布

借鉴 PoreSpy [Gostick 等, 2019] 的 MIS（最大内切球）法，将 PNM 孔隙分析工具映射到 NN 权重空间。在 GPT-2 (124M) 和 Pythia-70m [Biderman 等, 2023] 上完成六项实验。

8.1 权重" 孔径分布" 与 PoreSpy 对比

将 $|w_{ij}|$ 视为孔喉直径：大 $|w|$= 大孔喉 = 信号易通过。取绝对值是有意的简化——PNM 中孔喉直径始终为正。负权重（抑制性连接）的信息调制作用在此映射中未被捕捉。GPT-2 的 124M 权重：均值 0.102，" 堵孔率"($|w| < 10^{-6}$)=0%，" 大孔率"($|w| > 0.1$)=41%。log 域偏度 -1.44（左偏），偏离天然砂岩的对数正态分布。

用 PoreSpy 生成 3D 随机多孔介质（$\phi = 0.3, 0.5, 0.7$），做 Weibull 拟合和尾部指数对比：NN 的 Weibull 形状参数 $k = 1.14$（指数型），PNM 为 $k = 2.4$–2.9（有峰型）。尾部指数：NN $\alpha_{\text{tail}} = 4.36$（中等重尾），PNM 为 8–10（轻尾）。但 rank 归一化后，NN 与 PNM ($\phi = 0.7$) 的相关系数达 **0.98**——消除尺度差异后，分布形状高度相似。

解读：NN 权重与 PNM 孔径属不同分布族但共享组织原理。NN 发展出比天然岩石更极端的异质结构——更像人工定向孔道材料而非天然砂岩。

8.2 训练即渗流通道优化（实验 4）

对比随机初始化与预训练 GPT-2：训练使 $|w|$ 均值增长 6.4×，标准差增长 7.3×，大孔率从 0% 升至 41%。训练并非均匀放大所有权重，而是选择性放大少数主导路径、抑制其余——PNM 中优势渗流路径形成过程的直接对应。

8.3 训练过程的三阶段相变（实验 4b）

用 Pythia-70m 的 15 个公开 checkpoint（step 0 至 143,000），追踪全部 2D 权重矩阵的变异系数（CV）和基尼系数。发现三个阶段，与 PNM 驱替过程直接对应：

1. **蓄压期**（step 0–1,000）：CV 稳定在 0.795，权重几乎不变。PNM 类比：驱替压力未达启动阈值。
2. **突破期**（step 1,000–16,000）：$|w|$ 均值翻倍，大孔率峰值 8.4%。PNM 类比：流体侵入最大孔喉。
3. **重组期**（step 32,000–143,000）：大孔率从 step 32k 起下降（8.6%→1.1%），CV 持续加速上升（0.85→1.51）。$|w|$ 均值反降（0.045→0.026），少数主通道被选中放大，其余被抑制。最陡 CV 跳变在 step 64k→128k（ΔCV= +0.49）。PNM 类比：优势渗流路径选择导致巨连通分量形成。

相变是渐进而非阶跃的：CV 从 0.82（step 16k）连续经过 0.85、0.89、0.96 升至 1.45（step 128k）。最陡段（64k→128k）是渗流阈值跨越的 NN 对应。

训练位置与变化量级。 以总训练步数 (143k) 为基准：蓄压占 0–1%，突破占 1–11%，重组占 22–100%。最陡 CV 跳变 (64k→128k) 在训练的 45%–90% 处——远在损失基本收敛之后。CV 从 0.82 增至 1.51 是 84% 的增长；跨过 CV=1 意味着标准差超过均值，权重分布从单峰主导转为重尾极端值主导。渗流对应：阈值以下，所有孔喉承载相近流量（CV<1，均质）；阈值以上，少数主通道承载大部分流量而其余近乎闲置（CV>1，异质）。这是有限系统中无限集团形成的标志——不是均匀的连通性扩展，而是**骨架网络**的涌现。

诚实说明。 Pythia 每 1,000 步提供一个 checkpoint；本实验采样了 13 个代表性节点。16k–64k 过渡区间内有 49 个可用 checkpoint，加密采样可获得更精确的相变位置。三阶段模式仅在 Pythia-70m 上验证，待更大模型确认尺度不变性。三阶段分解为描述性的，非理论推导。

9 与已有工作的关系

Lubana 等（2024） [Lubana 等, 2024] 用渗流理论解释 Transformer 涌现，建立单阈值相变模型。NPM 将其扩展为多阈值场。

Brill（2024） [Brill, 2024] 在 Bethe 格上从第一性原理严格推导幂律扩展律。诚实评估：在扩展律这一具体问题上，NPM 并未超越 Brill——Brill 的推导更严格。NPM 相对于 Brill 的贡献在于范围而非深度：多阈值场视角、架构统一、σ 量化是真正的差异化贡献。

10 框架定位

Table 9: NPM 与历史工程框架的对比

框架	基础	参数	影响	NPM 类比
达西定律（1856）	经验	K（拟合）	170 年	$\rho = N_B/\exp(\alpha\sigma)$
雷诺数（1883）	量纲	Re_c	通用	$C_n = \rho/\rho_c$
k-ε（1972）	半经验	6 个常数	CFD 标准	α, β, δ

评价标准：逻辑自洽（已验证）、物理可解释（已展示）、参数可拟合（计划中）、预测有泛化性（部分展示）。

11 PNM–NN 类比的边界

工程类比的价值取决于对其适用边界的清晰认识。本节明确列出 PNM 与 NN 之间哪些可类比、哪些不可类比，以及差异本身带来的启示。

11.1 可类比项

Table 10: PNM–NN 可类比项

PNM 现象	NN 对应	依据
毛管启动压力：$\Delta P < P_{c,\text{entry}}$ 时流量为零	激活函数阈值：$x < 0$ 时 ReLU 输出为零	两者均为硬阈值截断；不同孔径/神经元的阈值不同，依次”打开”
相对渗透率：$k_{r,w} + k_{r,o} < 1$，两相共流时总导通 < 各相单独之和	多类型信息竞争：多语言模型每种语言性能 < 对应单语言模型	Conneau 等 [2020] 实证的”多语言诅咒”与相对渗透率曲线定性一致
压力扰动驱替：注入流体施加压力梯度，驱替气相，改变润湿界面	微调：少量定向数据施加梯度扰动，填补知识空白，改变网络对特定领域的响应	两者均为小段塞/少量数据驱动的局部状态重分布

11.2 不可类比项

Table 11: PNM–NN 不可类比项

PNM 特征	NN 差异	意义
粘性损耗连续：$Q \propto \Delta P/\mu$，能量沿路径连续耗散	信息传递近乎无损：激活值通过矩阵乘法精确传递，损失来自阈值截断而非连续耗散	NN 中不存在”信息粘度”；损耗是离散的（ReLU 截断、dropout），不是连续的
流体守恒：质量/体积严格守恒	信息可复制/放大：同一激活值可被多个下游神经元读取，广播不消耗”量”	注意力机制同时读取所有 token，流体无法同时在所有管道中”被读取”
孔隙结构固定（短期）：岩石不因流体通过而改变	网络权重随训练改变：反向传播持续修改”孔隙结构”	训练 = 流体一边流动一边改造岩石，PNM 中无直接对应
连续介质假设：达西定律假设 REV 内统计均匀	离散结构：NN 的层、神经元是离散的，不满足连续假设	从渗流理论借来的连续指数（β 等）在 NN 中可能需要修正

11.3 差异带来的启示

上述不可类比项不是框架的缺陷，而是指出了 NN 相对于 PNM 的**独特特征**，可能成为新理论的突破口：

- **信息可复制性**使得注意力机制成为可能——它在 PNM 中没有对应物，可能需要超越经典输运理论的新数学。
- **训练改变结构**意味着 NN 是一个”自适应多孔介质”——孔隙结构在流动过程中被流体雕刻。地质中最接近的过程是溶蚀（dissolution），化学反应改变孔隙结构，已有成熟的反应-输运耦合模型。
- **信息干扰**（矛盾数据相互抵消）在 PNM 中最接近的对应是化学反应输运：$\partial c/\partial t = D\nabla^2 c - k \cdot c_A \cdot c_B$，反应项消耗对冲物质。这可能为理解幻觉（hallucination）提供定量工具。

12 未来方向

B 路径 1：最优 W_{eff}（最大流理论）。给定参数量，何种 W_{eff} 构造使 C_{eff} 最大？若解决，注意力机制将从”工程发明”变为”最优信息传输的物理必然推论”。

B 路径 2：激活函数与毛管启动压力。ReLU 阈值类比毛管启动压力 $P_{c,\text{entry}}$。不同孔径的启动压力分布可从 MICP 曲线获得；最大化相变灵敏度的最优阈值分布可能从渗流临界理论推导。

B 路径 3：相对渗透率与多类型信息竞争。多语言/多模态训练中的能力折损类比多相流的 $k_{r,1} + k_{r,2} < 1$。若能建立 NN 版本的 Corey/Brooks-Corey 相对渗透率模型，可定量预测混合训练的效率损失。

B 路径 4：三阶段相变的规模验证。蓄压-突破-重组模式（第8.3节）仅在 Pythia-70m 上验证。在 Pythia-160m/410m/1B 上重复，检验相变步数（占总训练步的比例）是否尺度不变——渗流普适性预测应如此。

B 路径 5：$P_{\min}$ 解耦。当前 α 同时出现在 $V(\sigma)$ 和 $P_{\min}$ 中，产生矛盾约束（§7.3）。引入独立指数或将参数量 P 纳入 C_{eff} 是两条最有希望的路径。

13 结论

本文提出神经渗流模型（NPM），将孔网络物理映射到神经网络信息传播的统一工程框架。A 层检查确认了 GCN/注意力的定义一致性。B 层参数已用 14 个公开模型和 Kaplan 定律拟合校准，Spearman 相关 0.70，扩展律指数 $N^{0.076}$ 精确匹配。拟合 $\beta = 0.068$ 偏离 3D 渗流理论值 0.41，我们诚实讨论了这一偏差的三个可能原因。

MIS 孔隙分析发现 NN 权重分布与 PNM 孔径分布消除尺度后形状高度相似（rank 相关 0.98），但属不同分布族（Weibull $k = 1.1$ vs 2.5）。更重要的是，Pythia-70m 训练呈现三阶段相变——蓄压、突破、重组——CV 在 step 64k 至 128k 间从 0.82 暴增至 1.51，直接对应渗流理论中的巨连通分量形成。

C_n 作为无量纲判据能解释参数量无法解释的反常（如 BLOOM-176B 弱于 LLaMA-7B），但 σ 的客观测量仍是瓶颈。NPM 的价值在于为工程实践者提供连贯的物理词汇，联合推理数据、架构和能力。

代码与数据可用性。 https://github.com/tiexinding/neural-percolation-model。含全部实验结果的存档版本：https://zenodo.org/records/19209722。

致谢。 作者使用 Claude（Anthropic）作为写作辅助工具。所有理论内容、概念框架、方程和结论均为作者独立的知识贡献。本文英文预印本已发布于 Zenodo，DOI: 10.5281/zenodo.19209722。

合作邀请。 本预印本是开放合作邀请。作者积极寻求拥有 Pythia/OLMo checkpoint 的研究者进行定量验证，以及能够深化 Transformer–PNM 映射的理论研究者。

References

Biderman, S., et al. (2023). Pythia: A suite for analyzing large language models across training and scaling. *ICML 2023*.

Erdős, P., & Rényi, A. (1960). On the evolution of random graphs. *Publ. Math. Inst. Hungar. Acad. Sci.*, 5, 17–61.

Gostick, J., et al. (2019). PoreSpy: A Python toolkit for quantitative analysis of porous media images. *JOSS*, 4(37), 1296.

Brill, J. (2024). Deriving scaling laws from percolation theory. *arXiv preprint arXiv:2412.07942*.

Conneau, A., et al. (2020). Unsupervised cross-lingual representation learning at scale. *ACL 2020*.

Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *ICLR 2017*.

Hoffmann, J., et al. (2022). Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*.

Kaplan, J., et al. (2020). Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*.

Lubana, E., et al. (2024). Percolation-based emergence in Transformers. *arXiv preprint arXiv:2408.12578*.

Srinivasan, S., & Knackstedt, M. (2004). Pore network modelling of effective diffusivity. *Transport in Porous Media*, 56(1), 95–119.

Vaswani, A., et al. (2017). Attention is all you need. *NeurIPS 30*.

Wei, J., et al. (2022). Emergent abilities of large language models. *TMLR*.